

*Deep features* definidas a partir de modelo  
CNN híbrido: uma investigação para classificar  
e reconhecer padrões em imagens médicas

João Manoel Cardoso Martinez


# Sumário

1. Introdução
  - 1.1. Trabalhos Relacionados
  - 1.2. Objetivos
2. Metodologia
  - 2.1. Contexto de Aplicação
  - 2.2. Etapa 1: Aplicação da arquitetura ResNet101
  - 2.3. Etapa 2: Extração e seleção de *deep features*
  - 2.4. Etapa 3: Classificações com *fine tuning* de múltiplos classificadores
  - 2.5. Ferramentas utilizadas
3. Resultados e Discussão
4. Conclusão
5. Referências

# Introdução

# 1. Introdução

- A análise de imagens histológicas pode ajudar na detecção de doenças e diagnósticos;
- **Possuem alto potencial de exploração;**
  - Extração e aprendizado de padrões;
- **A extração de atributos requer condições específicas;**



**Figura 1:** Exemplo de imagem H&E.

# 1. Introdução

- Técnicas de aprendizado profundo são apropriadas;
- Uma dessas técnicas é a utilização de Redes Neurais Convolucionais;
  - Possuem grande poder de abstração;
  - Permitem a extração de **deep features** das imagens;
  - Evita o processamento de dados naturais em forma bruta;
- É possível utilizar o poder de abstração das CNN com classificadores externos à rede, o que denota um **modelo híbrido**.

# 1. Introdução

- Segundo a literatura especializada:
  - Modelos híbridos se destacam por serem estratégias eficientes e computacionalmente acessíveis;
  - Apresentam resultados iguais ou até melhores que os fornecidos por um modelo específico de CNN.
- Ao utilizar classificadores para categorizar *deep features* em um método supervisionado, uma das etapas é o ranqueamento de dos atributos mais relevantes;
  - Contribui na eficácia da identificação das características mais importantes

# 1. Introdução / 1.1 Trabalhos Relacionados

- A utilização de CNNs com classificadores externos em contextos de imagens médicas foi explorada em estudos recentes;
- Em Gupta et al., 2022 foram exploradas quatro arquiteturas CNN pré-treinadas (**VGG16**, **VGG19**, **Inception v3** e **SqueezeNet**) junto de classificadores como **Random Forest**, **KNN**, **SVM**, entre outros:
  - *Dataset* utilizado: 780 imagens de 500x500 pixels, com três classes: normal, benigno e maligno;
  - **Resultado**: acurácia de **92,9%**.

# 1. Introdução / 1.1 Trabalhos Relacionados

- Em Prezja et al., 2023 foi proposto um modelo híbrido para melhorar as abordagens comuns da utilização de CNN na classificação de imagens médicas:
  - **Dataset:** 100000 imagens de câncer colorretal, de 224x224 pixels e 9 classes distintas;
  - **Método:** utilizou a arquitetura *EfficientNetV2* com o classificador *Random Forest*;
  - **Resultado:** taxas de acurácia entre **96,74%** e **99,89%**.
- Ambos os trabalhos denotam o potencial da estratégia de modelos híbridos para a classificação de imagens médicas.



# 1. Introdução / 1.2 Objetivos

- Neste projeto foi proposto uma investigação exploratória de imagens histológicas H&E por uma arquitetura CNN e auxílio de classificadores externos;
- Os principais objetivos são:
  - Utilizar uma arquitetura CNN para coletar as *deep features* de cada *dataset* utilizado;
  - Avaliar o poder discriminativo das melhores *deep features* em diferentes composições e classificadores consolidados na área de aprendizado de máquina;
  - Indicar a classificação mais apropriada.

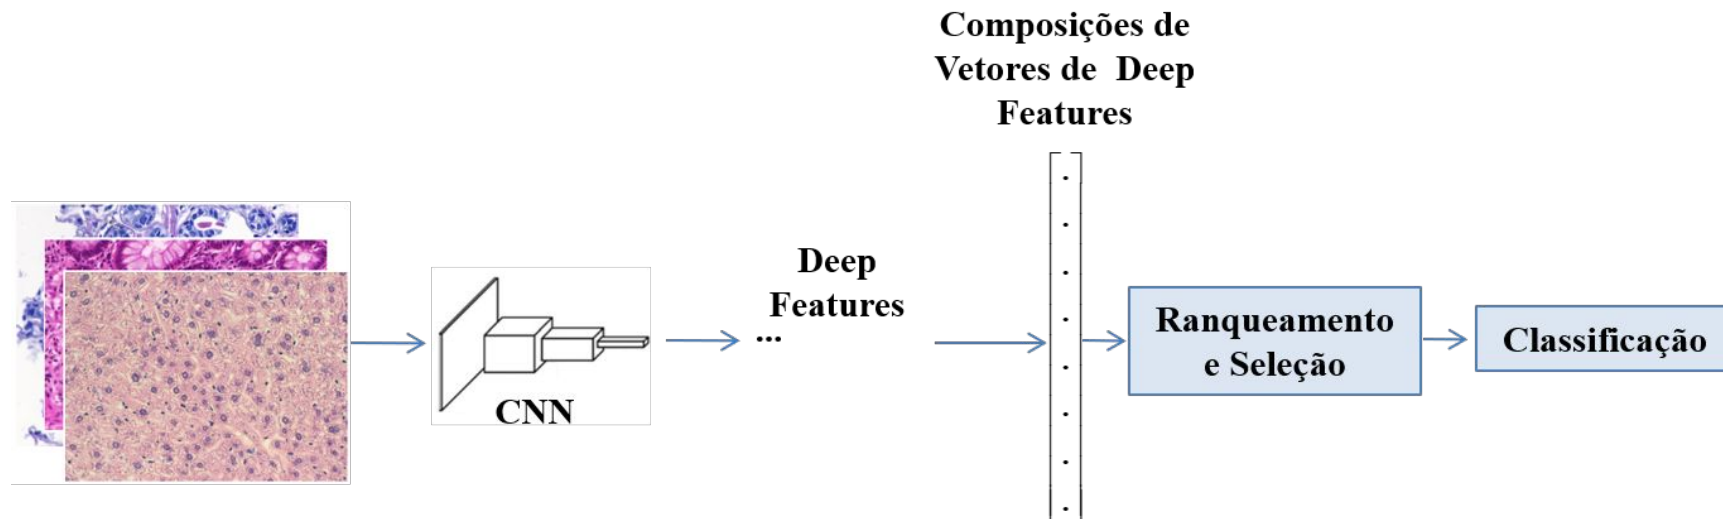
# Metodologia

## 2. Metodologia

O método proposto foi conduzido em três etapas:

- **Etapa 1:** Aplicação de uma Rede Neural Convolucional;
- **Etapa 2:** Extração e ranqueamento das *deep features*;
- **Etapa 3:** Classificações com *fine tuning* de múltiplos classificadores;

## 2. Metodologia



**Figura 2:** Diagrama do método proposto.

## 2. Metodologia / 2.1 Contexto de aplicação

Imagens H&E com importância científica reconhecida, representativas de:

- Câncer de mama (**UCSB**): 58 imagens, 768x896, 32 benignos e 26 malignos;
- Câncer colorretal (**CR**): 151 imagens, 775x522, 67 benignos e 84 malignos;
- Tecido hepático (**LG**): 265 imagens, 417x312, 150 macho e 115 fêmea;
- Displasia oral (**DISP**): 148 imagens, 2048x1523, 74 saudáveis e 74 displasia severa (maligno).

## 2. Metodologia / 2.2 Etapa 1

Cada conjunto de imagens H&E foi analisado pela modelo CNN ResNet101;

- O modelo utilizou:
  - Técnica ***transfer-learning*** via base ***ImageNet***;
  - *Fine-tuning*;
  - *K-fold cross-validation*.
- Para a implementação, foi utilizado o github GCC-Toolkit:
  - <https://github.com/leonardohcl/GCC-Toolkit.git>

## 2. Metodologia / 2.2 Etapa 1

- Parâmetros utilizados:
  - *Learning rate* = 0,01;
  - *Epochs* = 10;
  - *K* = 2
  - *Learning rate drop* = 0,75 a cada 2 *epochs*;
  - **Classes** = [0, 1] -> Benigno e Maligno (**UCSB, CR, DISP**) ou Macho e Fêmea (**LG**).

## 2. Metodologia / 2.3 Etapa 2

Obtenção de *deep features* de cada *dataset*.

- Extração de *deep features*:
  - Mesmos métodos e parâmetros da **Etapa 1**;
  - Extração de características da camada de *average pooling*;
  - *Deep features* salvas em arquivos .arff.



## 2. Metodologia / 2.3 Etapa 2

As *deep features* extraídas foram transformadas em *data frames* e submetidas ao algoritmo **SelectKBest**.

- Ranqueamento via **SelectKBest**
  - Seleciona as *features* de acordo com os **k** melhores valores;
  - Qualidade e relevância de cada atributo por testes estatísticos univariados.
- Análise de desempenho
  - Diferentes composições das **melhores** *features* ranqueadas;
  - Vetores com 10, 20, 30, 40, 50 e 100 *features*.
- Algoritmo aplicado com a biblioteca *Scikit-Learn*.

## 2. Metodologia / 2.4 Etapa 3

Análise da capacidade de classificação das características pelos seguintes classificadores:

- *Random Forest* (**RandF**);
- *K-Nearest Neighbors* (**KNN**);
- *Decision Tree* (**DecTree**);
- *AdaBoost* (**AdaBst**).

## 2. Metodologia / 2.4 Etapa 3

Todos os classificadores foram aplicados com *fine tuning* via **GridSearchCV** para cada composição de *features*, a fim de se obter a melhor métrica de desempenho entre todos os vetores analisados para cada *dataset*;

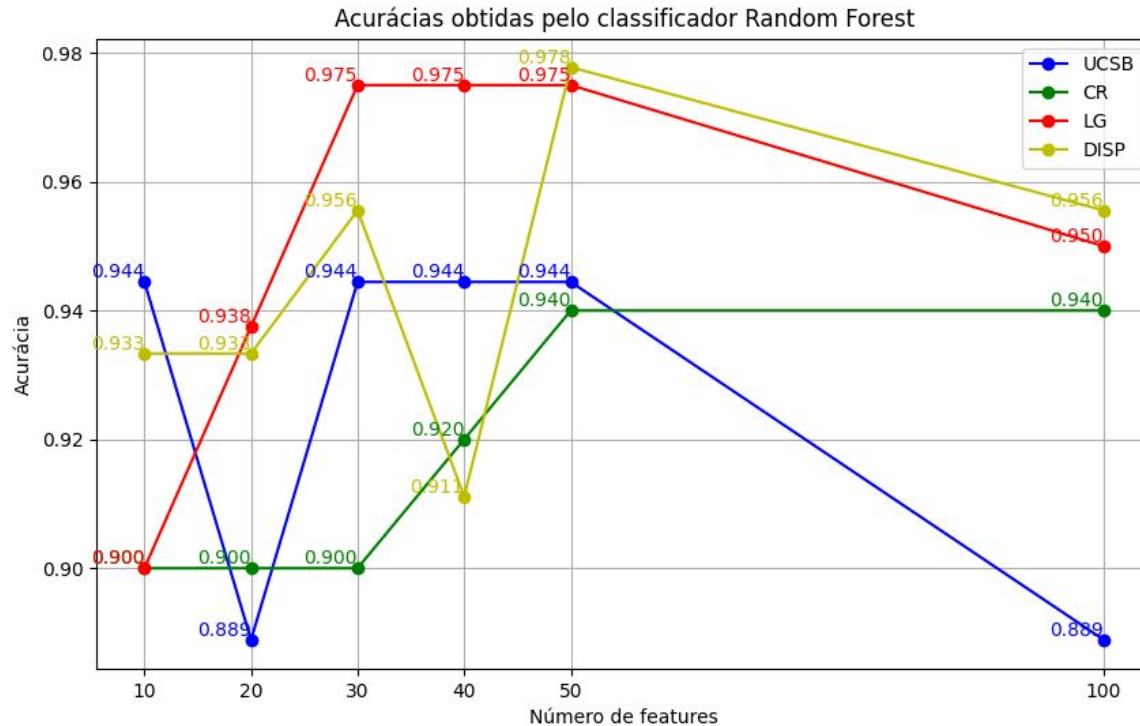
- Métricas avaliadas:
  - Acurácia (**Acc**);
    - **Assertividade** e **exatidão** dos resultados;
  - Área sob a curvatura ROC (**AUC**);
    - Poder **discriminativo** do classificador;
  - **F1-Score**;
    - **Qualidade** e **confiabilidade** geral da classificação.

## 2. Metodologia / 2.5 Ferramentas utilizadas

- Linguagem *Python*:
  - PyTorch;
- *Scikit-Learn*:
  - Ranqueamento via *SelectKBest*;
  - Aplicação dos classificadores e *GridSearchCV*;
- Máquina utilizada para a execução:
  - Notebook Acer Aspire 3;
  - Intel i3-6006U (2.0 GHz);
  - 4 GB RAM;
  - Plataforma Google Colab
  - GPU T4 disponível na plataforma.

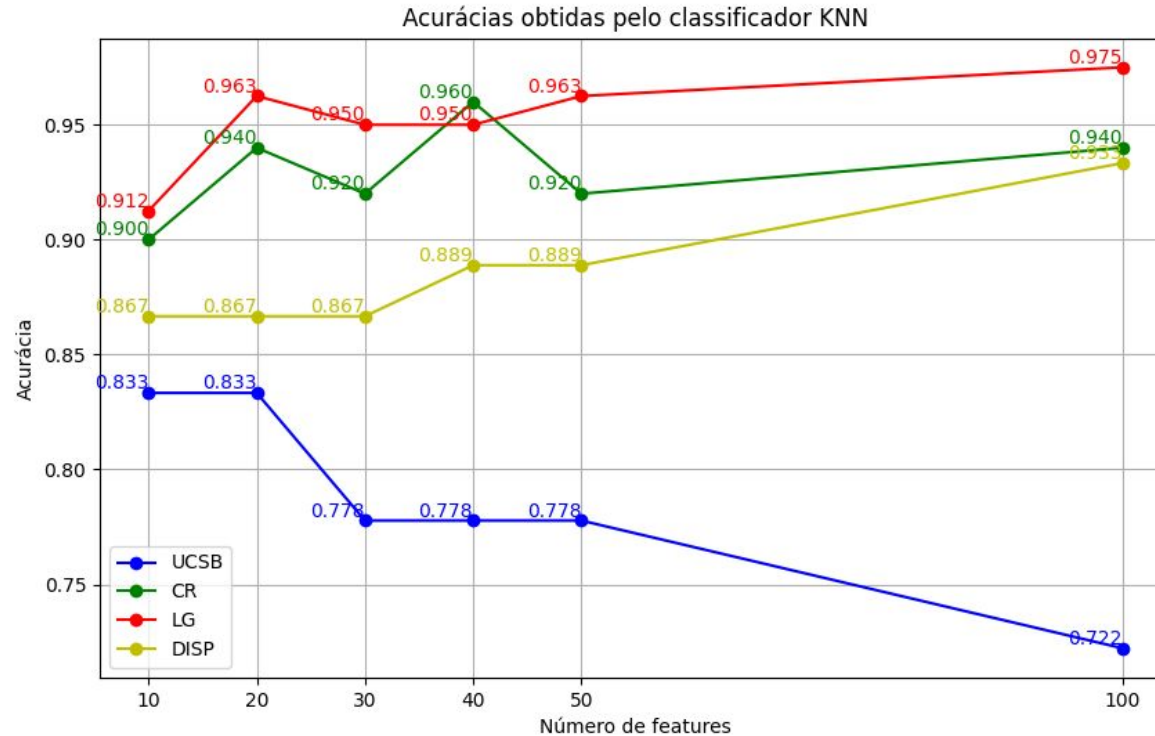
# Resultados e Discussão

### 3. Resultados e Discussão



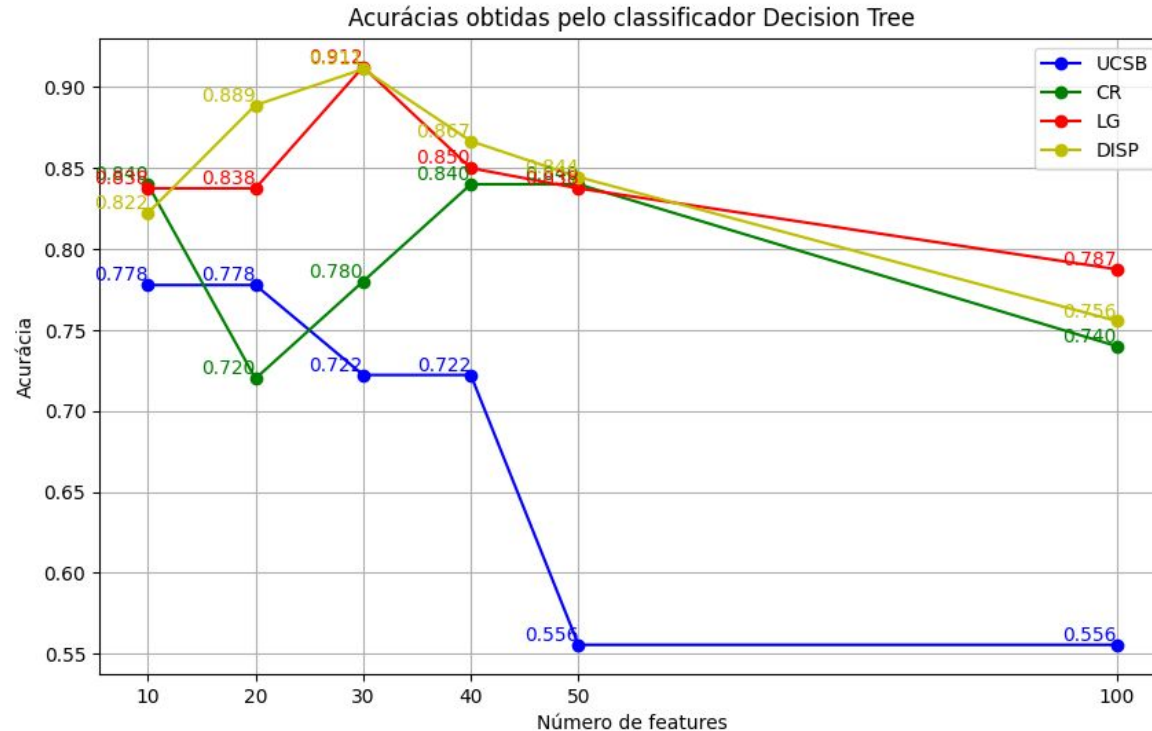
**Figura 1:** Acurácias obtidas pelo classificador *Random Forest* em cada *dataset*.

### 3. Resultados e Discussão



**Figura 2:** Acurácias obtidas pelo classificador *KNN* em cada *dataset*.

### 3. Resultados e Discussão



**Figura 3:** Acurácias obtidas pelo classificador *Decision Tree* em cada *dataset*.



### 3. Resultados e Discussão

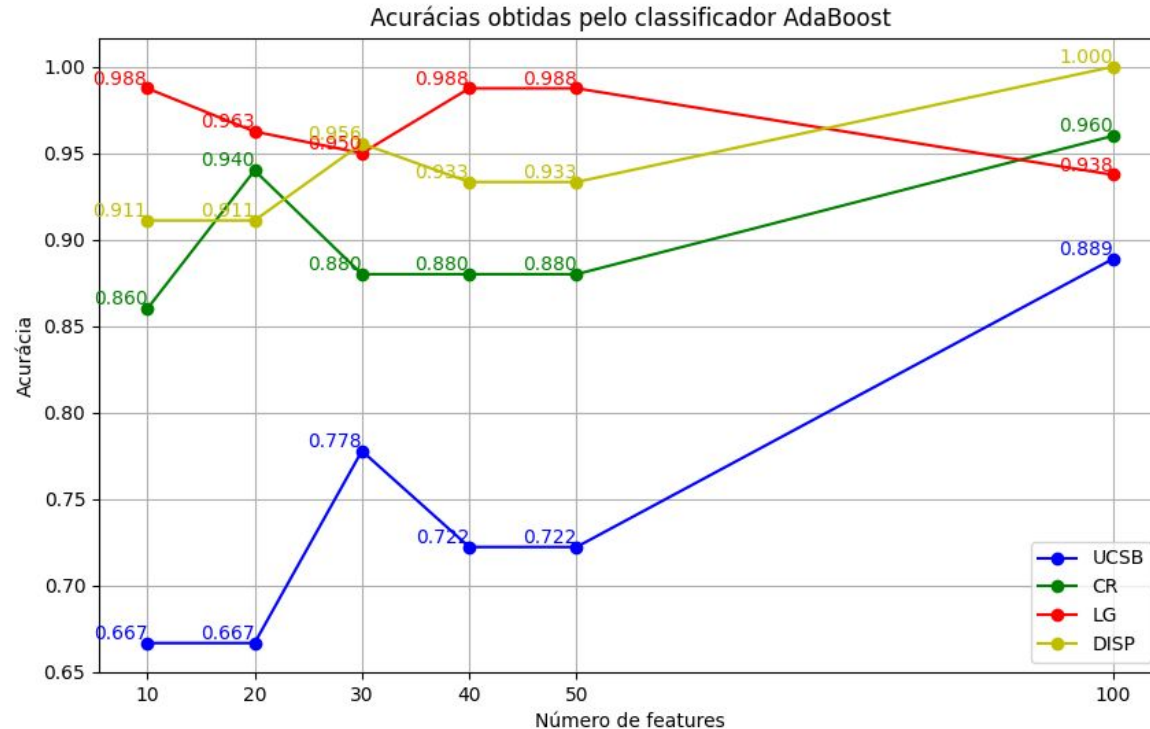


Figura 4: Acurácias obtidas pelo classificador *AdaBoost* em cada *dataset*.

### 3. Resultados e Discussão

Os melhores resultados, considerando a melhor taxa de **AUC** (melhor poder de discriminação) para o menor número de *features*, em cada classificador estão presentes na tabela abaixo:

	Total de features	Classificador	AUC	Acc (%)	F1-Score
UCSB	10	RandF	0,937	94,44	0,933
CR	40	KNN	0,954	96	0,965
LG	10	AdaBst	0,985	98,75	0,985
DISP	50	RandF	0,978	97,77	0,977

**Tabela 1:** Sumarização dos melhores resultados baseados na AUC alcançada por cada base de dados.

### 3. Resultados e Discussão

É possível comparar as melhores taxas de acurácia obtidas em cada base pelo método proposto, com as alcançadas pela rede *ResNet101* aplicada isoladamente em cada um dos *datasets*.

	UCSB	CR	LG	DISP
ResNet101	76,67	89,29	96,97	96,43
Proposto	94,44	96	98,75	97,77
Diferença	19,77	6,71	1,78	1,34

**Tabela 2:** Comparação das melhores acurácias (%) entre a aplicação da *ResNet101* e do modelo proposto.

### 3. Resultados e Discussão

- É evidente a melhora no desempenho de acurácia para o *dataset* de câncer de mama (**UCSB**), provavelmente por razão do número reduzido de amostras que compõem o conjunto de dados.
  - Diferença de **19,77** nas taxas obtidas;
- Para as demais bases, a diferença não foi expressiva, porém mesmo assim foram superiores às obtidas pela aplicação da arquitetura CNN de forma isolada;
  - Diferenças entre **1,34 (DISP)** e **6,71 (CR)**.

# Conclusão

## 4 - Conclusão

- Resultados podem ser valiosos para o desenvolvimento de técnicas e algoritmos aplicáveis em sistemas de diagnósticos auxiliados por computador, no contexto de imagens histológicas.
- **Trabalhos futuros:**
  - Explorar outras arquiteturas CNN;
  - Implementar associações entre arquiteturas CNN distintas;
  - Analisar o desempenho em outros classificadores;
  - Utilizar conjuntos de dados com múltiplas classes.

- GUPTA, S. et al. Employing deep learning feature extraction models with learning classifiers to diagnose breast cancer in medical images. In: 2022 IEEE Delhi Section Conference (DELCON). [S.l.: s.n.], 2022. p. 1–6.
- PREZJA, F. et al. Improving performance in colorectal cancer histology decomposition using deep and ensemble machine learning. arXiv preprint arXiv:2310.16954, 2023.
- DABEER, S.; KHAN, M. M.; ISLAM, S. Cancer diagnosis in histopathological image: Cnn based approach. Informatics in Medicine Unlocked, Elsevier, p. 100231, 2019.
- COCCIA, M. Deep learning technology for improving cancer care in society: New directions in cancer imaging driven by artificial intelligence. Technology in Society, Elsevier, v. 60, p. 101198, 2020.

# Muito obrigado!

Estou aberto para perguntas

[joao.c.martinez@unesp.br](mailto:joao.c.martinez@unesp.br)

**unesp** 